

# KBO 관중수 예측 분석




## KBO& MLB 관중수 예측 분석 및 세이버 매트릭스



팀: 올해는 우승



팀장: 최서연 팀원: 허수빈



# Table of Contents



시계열 데이터 검증과 스포츠 데이터로의 확장



01

데이터셋 설명, 수집 방법

데이터 크롤링 및 수집 방법과 완성된 데이터셋에 대한 설명

02

KBO 관중수 분석, 예측

만들어진 데이터셋을 기반으로 데이터 분석 및 관중수 예측 모델 작성

03

MLB 관중수 분석, 예측

KBO를 넘어서 MLB 데이터에 대한 분석으로의 확장과 관중 수 예측

04

시계열 데이터 적합성

시계열 데이터로 보이는 야구 데이터가 시계열 데이터로 적합한지에 대한 평가

05

sabermetrics로의 확장

데이터 기반으로 스포츠 데이터의 정수인 sabermetrics로의 확장성

# 01




## 데이터셋 설명, 수집방법



KBO 홈페이지, 네이버스포츠



기상청 기상자료개방포털



# 데이터셋 설명, 수집방법



KBO 홈페이지-기록순위-관중현황 크롤링



KBO 홈페이지에서 2023,2024,2025 정규시즌 일자별 관중수를 크롤링하여 데이터를 가져왔습니다.



KBO 홈페이지

KBO, 한국야구위원회, 프로야구, KBO 리그, 퓨처스리그, 프로야구순위, 프로야구 일정

koreabaseball.com /

일정·결과

기록·순위

선수

미디어·뉴스

KBO

퓨처스리그

KBO 마켓

KBO 폰트



홈 > 기록·순위 > 관중 현황

## 관중 현황

KBO 정규시즌

역대 관중 현황

구단별 관중 현황

일자별 관중 현황

연도별 관중 현황

검색항목

2024

월별

팀별

홈/방문별

구장별

요일별

검색

\* 경기 관중 현황(월:전체, 팀:전체, 홈/방문:전체, 구장:전체, 요일:전체)

| 날짜         | 요일 | 홈   | 방문 | 구장 | 관중수    |
|------------|----|-----|----|----|--------|
| 2024/03/23 | 토  | LG  | 한화 | 잠실 | 23,750 |
| 2024/03/23 | 토  | SSG | 롯데 | 문학 | 23,000 |
| 2024/03/23 | 토  | NC  | 두산 | 창원 | 17,891 |
| 2024/03/23 | 토  | KT  | 삼성 | 수원 | 18,700 |
| 2024/03/23 | 토  | KIA | 키움 | 광주 | 20,500 |
| 2024/03/24 | 일  | LG  | 한화 | 잠실 | 23,750 |
| 2024/03/24 | 일  | SSG | 롯데 | 문학 | 23,000 |
| 2024/03/24 | 일  | NC  | 두산 | 창원 | 14,555 |

# 데이터셋 설명, 수집방법



기상청 기상자료개방포털



기상자료개방포털에서 모든 구장의 지역을 선택해 각 연도별 일시, 평균기온(°C), 일강수량(mm), 평균 풍속(m/s), 합계 일사량(MJ/m2), 평균 전운량(1/10), 평균 상대습도(%)를 csv로 가져와 KBO데이터와 합쳐졌습니다.



## 기상청 기상자료개방포털

말하기:

자료형태일 자료

기간20230401 ~ 20251004

지점지도로 선택

지명으로 가까운 지점 조회

조회

☒ 전체

☐ 강원특별자치도

☒ 경기도

☒ 경상남도

☐ 경상북도

☐ 광주광역시

☒ 대구광역시

☒ 대전광역시

☒ 부산광역시

☒ 서울특별시

☐ 세종특별자치시

☐ 울산광역시

☒ 인천광역시

☒ 전체

☒ 기온

☒ 평균기온

☐ 최저기온

☐ 최저기온 시각

☐ 최고기온

☐ 최고기온 시각

☒ 강수

☐ 강수 계속시간

☐ 10분 최다 강수량

☐ 10분 최다강수량 시각

☐ 1시간 최다강수량

☐ 1시간 최다 강수량 시각

> 조회

자료보기

CSVExcel

※조회 결과는 10건만 표출 됩니다. 상세결과는 파일 다운로드를 이용해주세요

| 지점      | 시간         | 평균기온(°C) | 일강수량(mm) | 평균 풍속(m/s) | 합계 일사량(MJ/m2) | 평균 전운량(1/10) |
|---------|------------|----------|----------|------------|---------------|--------------|
| 서울(108) | 2023-04-01 | 17.5     |          | 1.8        | 21.48         | 1.8          |
| 서울(108) | 2023-04-02 | 18.8     |          | 2.4        | 24.08         | 0.4          |
| 서울(108) | 2023-04-03 | 19       |          | 2.3        | 22.95         | 4.1          |
| 서울(108) | 2023-04-04 | 17.6     | 6.9      | 2.6        | 10.78         | 9.1          |
| 서울(108) | 2023-04-05 | 11.9     | 50.3     | 3.4        | 1.56          | 10           |

# 데이터셋 설명, 수집방법



네이버 스포츠 - 야구 일정



2023-2025년의 경기일정과 경기시간, 경기의 승패, 더블헤더 기록, 홈팀, 원정팀 정보를 네이버 스포츠에서 html 코드를 저장시켜 원하는 정보만 추출해 사용했습니다.



스포츠

최근 < 2023 >

3월 4월 5월 6월 7월 8월 9월 10월 11월 12월 1월 2월 포스트시즌



4월 1일 (토)

|       |    |              |    |    |    |             |                            |    |    |
|-------|----|--------------|----|----|----|-------------|----------------------------|----|----|
| 14:00 | 고척 | 한화<br>장시환 궤  | 2  | 중요 | 3  | 키움<br>문성현   | KBS2                       | 영상 | 기록 |
| 14:00 | 문학 | KIA<br>앤더슨 궤 | 1  | 중요 | 4  | SSG<br>김광현  | MBC                        | 영상 | 기록 |
| 14:00 | 수원 | LG<br>펠라 궤   | 6  | 중요 | 11 | KT<br>벤지민   | MBC SPORTS+<br>SPOTV       | 영상 | 기록 |
| 14:00 | 잠실 | 롯데<br>문경산 궤  | 10 | 중요 | 12 | 두산<br>최지강   | SBS                        | 영상 | 기록 |
| 14:00 | 대구 | NC<br>패디 궤   | 8  | 중요 | 0  | 삼성<br>패 부캐년 | KBS N SPORTS<br>SBS SPORTS | 영상 | 기록 |

4월 2일 (일)

|       |    |              |    |    |   |              |              |    |    |
|-------|----|--------------|----|----|---|--------------|--------------|----|----|
| 14:00 | 고척 | 한화<br>주현상 궤  | 6  | 중요 | 7 | 키움<br>김재홍    | SPOTV2       | 영상 | 기록 |
| 14:00 | 문학 | KIA<br>이와리 궤 | 9  | 중요 | 5 | SSG<br>패 맥카티 | SBS SPORTS   | 영상 | 기록 |
| 14:00 | 수원 | LG<br>살다주 궤  | 10 | 중요 | 9 | KT<br>패 박영현  | SPOTV        | 영상 | 기록 |
| 14:00 | 잠실 | 롯데<br>나교안 궤  | 2  | 중요 | 0 | 두산<br>패 최광준  | KBS N SPORTS | 영상 | 기록 |
| 14:00 | 대구 | NC<br>김진호 궤  | 6  | 중요 | 8 | 삼성<br>패 이승현  | MBC SPORTS+  | 영상 | 기록 |

# 02




## KBO 관중수 분석,예측



전체 관중수 분석, 추이 예측



특정 팀별 관중수 분석, 추이 예측



# 완성된 데이터셋

|   | 날짜         | 경기_시간 | 상태   | 홈   | 방문  | 홈_점수 | 방문_점수 | 승리팀 | 경기_순번 | 더블헤더냐 | 제_진_행_순번 | 요일 | 구장 | 관중수   | 지점명 | 지점    | 평균기온(°C) | 일강수량(mm) | 평균 풍속(m/s) | 합계 일사량(MJ/m2) | 평균 전운량(1/10) | 연도   | 평균 상대습도(%) |
|---|------------|-------|------|-----|-----|------|-------|-----|-------|-------|----------|----|----|-------|-----|-------|----------|----------|------------|---------------|--------------|------|------------|
| 0 | 2023-04-01 | 14:00 | 정상종료 | KT  | LG  | 11   | 6     | KT  | 1     | 0     | 1        | 토  | 수원 | 18700 | 수원  | 119.0 | 14.7     | 0.0      | 1.4        | 21.67         | 0.5          | 2023 | 47.9       |
| 1 | 2023-04-01 | 14:00 | 정상종료 | SSG | KIA | 4    | 1     | SSG | 1     | 0     | 1        | 토  | 문학 | 23000 | 인천  | 112.0 | 15.0     | 0.0      | 1.9        | 21.56         | 1.3          | 2023 | 50.0       |
| 2 | 2023-04-01 | 14:00 | 정상종료 | 두산  | 롯데  | 12   | 10    | 두산  | 1     | 0     | 1        | 토  | 잠실 | 23750 | 서울  | 108.0 | 17.5     | 0.0      | 1.8        | 21.48         | 1.8          | 2023 | 40.4       |
| 3 | 2023-04-01 | 14:00 | 정상종료 | 삼성  | NC  | 0    | 8     | NC  | 1     | 0     | 1        | 토  | 대구 | 24000 | 대구  | 143.0 | 15.0     | 0.0      | 3.3        | 22.11         | 0.9          | 2023 | 54.5       |
| 4 | 2023-04-01 | 14:00 | 정상종료 | 키움  | 한화  | 3    | 2     | 키움  | 1     | 0     | 1        | 토  | 고척 | 16000 | 서울  | 108.0 | 17.5     | 0.0      | 1.8        | 21.48         | 1.8          | 2023 | 40.4       |


# 연도별 평균 관중 수 추이 비교




해가 지날수록 전체적으로 우상향



포스트 팬데믹 시대의 야구장은 단순한 관람석을 넘어, 독자적인 응원 문화와 결합된 '야외 체험형 엔터테인먼트 공간'으로 재정립되었습니다. 가족 및 MZ세대 관객의 수요가 체험 중심 콘텐츠와 맞물리며, 관중 동원력은 가파른 우상향 곡선을 그리며 질적·양적 성장을 거듭하고 있습니다.



# 연도별, 구장별 관중수 추세




# 구장 평균 관중수 분석


광주구장 평균 관중수 분석



대구구장 평균 관중수 분석




대전구장 평균 관중수 분석




문학구장 평균 관중수 분석



사직구장 평균 관중수 분석




수원구장 평균 관중수 분석




# 구장 평균 관중수 분석

상대팀 (방문)  
창원구장 평균 관중수 분석




고척구장 평균 관중수 분석



상대팀 (홈)  
잠실구장 (LG 홈경기) 평균 관중수 분석



잠실구장 (두산 홈경기) 평균 관중수 분석



# 시즌별 평일, 주말/공휴일 평균 관중수 비교




## 우상향 추세



2023,2024,2025 매년 평일,주말/공휴일의 관중수가 늘어나는 추세입니다.  
이전에는 평일과 주말/공휴일간의 차이가 심했다면, 그 간격마저 줄어드는 추세입니다.

연도별 평일 및 주말/공휴일 평균 관중수 비교




# 홈팀의 일간 순위에 따른 평균 관중수



순위가 높을수록 관중 ↑



전반적으로 순위가 높으면 높을수록 관중수가 많아집니다.



# 주요 라이벌 매치 및 일반 경기 평균 관중수 비교




## 주요 라이벌 매치



잠실더비 - LG,두산  
클래식 시리즈 - 삼성, 롯데  
엘롯라시코 - LG, 롯데  
낙동강 시리즈 - NC, 롯데  
88시리즈 - KIA, 삼성

일반경기에 비해 주요 라이벌 매치는 관중수가 높은편입니다.

주요 라이벌 매치 및 일반 경기 평균 관중수 비교



# 일반 일요일 경기와 더블헤더 관중수 비교




## 더블헤더는 관중수가 낮은편



더블헤더라는 것은 하루에 경기가 두번 치뤄 지는 것이기에 하루에 한번 경기 하는 일반경기보다 상대적으로 관중수가 낮은편입니다.

일반 일요일 경기와 더블헤더 관중수 비교



# 평일과 주말에 따른 더블헤더 관중수 비교




주말은 1차전, 평일은 2차전



더블헤더는 하루에 두번 경기하는 특성 상 경기 시간이 하루에 두번으로 대략 3-4시간 정도의 차이가 발생합니다.

주말의 경우에는 오전에 일찍 시작하는 1차전의 관중이 더 높은 반면, 평일의 경우에는 3시 경기 시작으로 관중 수가 적을 수 밖에 없고 2차전이 6시-7시 사이로 대부분의 일과가 끝나는 퇴근시간과 맞물려 더블헤더 2차전의 경기 관중수가 훨씬 많은 것을 확인할 수 있습니다



# KBO 관중수 예측 주요 변수 상관관계 분석



성적보다는 인기와 휴일 여부가 관건




- 홈팀 인기: 0.54
- 구장 수용인원: 0.50
- 휴일 여부: 0.37
- 라이벌 매치: 0.22
- 순위 경쟁도: 0.15
- 최근 성적: 0.14
- 강수량: -0.07

관중수는 구장 수용인원과 홈팀 인기의 영향을 가장 크게 받으며, 휴일 여부도 관중 증가에 유의미한 영향을 줍니다.

경기력 지표인 최근 성적과 순위 경쟁도 역시 관중수와 일정 수준의 양의 상관관계를 보여 영향이 완전히 없지는 않지만, 그 영향력은 인기나 환경 요인에 비해 상대적으로 작은 것으로 나타났습니다.

또한 강수량이나 시즌 진행률 등은 관중수와의 관련성이 낮고, 라이벌 매치는 보조적인 흥행 요인으로 작용하는 것으로 분석됩니다.

KBO 관중수 예측 주요 변수 상관관계 분석



# 데이터 전처리 및 피처 엔지니어링 (Feature Engineering)



[데이터 정제] - [날씨/환경] - [일정/시간] - [팀 상태/역동성]



## 데이터 정제 및 기반 구축 (Data Cleaning)

핵심 요약: 분석의 정확도를 높이기 위해 불규칙한 데이터를 정규화하고 기준 구장을 재정의하였습니다.

- **데이터 통합 및 매칭:** 경기 데이터와 기상청 날씨 데이터를 '지점'과 '날짜' 기준으로 병합(Merge)
- **구장 데이터 정규화:**
  - 제2구장(포항, 울산, 청주) 제외, 10개 구단 메인 홈 구장 데이터 집중 분석
  - 한밭 경기장을 '대전'으로 명칭 통일
- **가변 수용인원(Capacity) 반영:** 구장별 기본 수용인원 매핑
  - 연도별 변동성 반영: 사직 야구장 좌석수 변화 및 2025년 한화 신구장(17,000석) 증축 데이터 반영

# 데이터 전처리 및 피처 엔지니어링 (Feature Engineering)



[데이터 정제] - [날씨/환경] - [일정/시간] - [팀 상태/역동성]



## 환경 및 일정 파생 변수 (Weather & Schedule)

핵심 요약: 관중의 직관 결정에 영향을 미치는 외부 요인을 수치화

- [환경] 불쾌지수(Discomfort Index) 산출:
  - 단순 기온이 아닌 습도를 고려한 체감 지수 계산
  - $DI = \frac{9}{5}T - 0.55(1 - \frac{RH}{100})(\frac{9}{5}T - 26) + 32$
- [시간] 경기 시점 세분화:
  - 경기 시작 시간 라벨 인코딩(Label Encoding) 및 월별 시즌성 반영
- [휴일] 휴일 효과 극대화:
  - 주말(토/일) 및 법정 공휴일(어린이날, 추석 연휴 등)을 통합한 '휴일여부' 변수 생성

# 데이터 전처리 및 피처 엔지니어링 (Feature Engineering)



[데이터 정제] - [날씨/환경] - [일정/시간] - [팀 상태/역동성]



## 팀 성적 및 모멘텀 분석 (Team Dynamics)

핵심 요약: 팀의 현재 기세와 시즌 막의 중요도를 데이터로 구현

- 시즌 진행률 및 잔여 경기:
  - 홈 경기 기준(72경기) 시즌 진행률 산정하여 시기별 관중 변화 추적
- 홈팀 승리 모멘텀:
  - 최근 10경기 승률: 단순 성적이 아닌 경기 시점 기준의 '최근 기세'를 이동평균(Rolling)으로 산출
- 순위 경쟁도(Rank Competition):
  - 로직: (시즌 진행률) × (최근 승률)
  - 특징: 가을야구 진출팀이 결정되는 8월 이후, 시즌 막판의 긴박함과 팬들의 관심을 수치화

# 데이터 전처리 및 피처 엔지니어링 (Feature Engineering)



[데이터 정제] - [날씨/환경] - [일정/시간] - [팀 상태/역동성]



## 매치업 특성 및 흥행 잠재력 (Matchup Dynamics)

핵심 요약: 홈/원정팀의 브랜드 파워와 특수 관계(라이벌)를 통한 관중 동원력 분석

- **팀별 브랜드 인기도 (Team Popularity):** 홈팀 인기도: 구장 규모와 팬덤 크기를 반영한 홈팀별 평균 관중수 수치화
  - 원정팀 인기도: 원정 경기 시 해당 팀이 동원하는 평균 관중수를 산출하여 매치업의 '티켓 파워' 측정
  - 효과: 단순 팀명이 아닌 실질적 동원 능력(Numerical Value)을 모델에 학습시켜 예측 정밀도 향상
- **라이벌 매치 (Rivalry Match) 가중치:**
  - 특정 팀 간의 역사적, 지역적 라이벌 관계를 이진 변수(Binary)로 정의
  - 주요 타겟: LG-두산(잠실 더비), 롯데-LG(엘롯라시코), KIA-한화, 삼성-롯데 등
  - 효과: 일반적인 성적 지표로 설명되지 않는 '매진 임박' 매치업의 특수성 반영

# 모델 성능 비교 - 시계열 모델




## ARIMA, Chronos 모델 사용




시계열 모델인 ARIMA와 Chronos는 전혀 예측을 하지 못합니다. 실제 그래프의 굴곡을 하나도 잡아 내지 못하며 전부 평균으로 수렴해 버리는 문제가 발생하였습니다.

ARIMA는 초반에는 굴곡이 보이나 후반에는 굴곡이 사라져버리고, Chronos는 끝까지 굴곡이 존재하나 실제 그래프와 맞지 않는 모습을 보였습니다.


연도별 Test 기간 관중수 예측 결과 비교 (ARIMA vs Chronos)  
[2023년 시즌] 시계열 전용 모델 예측 비교 차트 (Test 기간)



[2024년 시즌] 시계열 전용 모델 예측 비교 차트 (Test 기간)



[2025년 시즌] 시계열 전용 모델 예측 비교 차트 (Test 기간)




# 모델 성능 비교 - 회귀 모델





XGBoost 모델 사용



전체적인 추이는 잘 따라가는 모습이 보입니다.  
하지만 기대치 R2 값인 0.7~0.8에는 못 미치게 나왔습니다.



# 모델 성능 비교 - 회귀모델



- ✓ R2 Score: 0.7968
- ✓ MAE (평균 오차): 2030.7명

- ✓ 최대 오차 발생 경기: 8820명
- ✓ 최소 오차 발생 경기: 6명
- ✓ 평균적으로 2030.7명 정도 틀리고 있습니다.

# 수도권 구장 잠실 과 고척의 관중수 분포 및 비율




같은 수도권이어도, 같은 구장이어도 분포, 비율이 다름




홈팀별 관중 수를 보면 LG와 두산이 키움보다 전반적으로 높은 수준을 유지합니다. LG는 관중 수의 저점 자체가 상대적으로 높게 형성되어 전반적으로 안정적인 흥행 구조를 보이는 반면, 두산은 높은 관중 수를 기록하는 경기들이 많지만 저점 구간도 함께 존재해 변동성이 더 큰 편입니다. 키움은 전체적으로 관중 수 수준이 가장 낮고, 경기별 편차도 크게 나타나는 특징을 보입니다.

좌석 점유율에서도 LG는 높은 구간에 밀집된 분포로 안정적인 관중 동원을 유지하는 반면, 두산은 넓은 범위에 분포해 변동성이 있고, 키움은 낮은 점유율 구간까지 넓게 퍼져 있어 불안정한 흥행 패턴을 보입니다.

홈 팀별 관중 수 분포



홈 팀별 좌석 점유율(%) 분포



# 돔구장의 여름철 점유율




## 8월에 압도적으로 관중수 증가




우리나라 유일 돔구장이라 고척은 평균적으로 낮은 관중수를 기록함에도 불구하고 여름에는 시원한 돔구장을 찾는 사람이 많은것으로 분석됩니다. 단순 관중수로 보면 고척 인원이 적을 수 있지만 다른 월의 점유율과 한여름인 8월의 점유율 비교하면 확연한 차이가 보입니다.

월별 돔구장 vs 야외구장 점유율 추이



# 시즌별 잠실(LG) 관중 수 예측 그래프

▶ LG | 2023년 시즌 후반 예측 추적



▶ LG | 2024년 시즌 후반 예측 추적



▶ LG | 2025년 시즌 후반 예측 추적



## 2023

- 전반적 추세는 반영되지만 변동성 큼
- XGB / LGBM: 급변 구간에서 오차 확대
- CatBoost: 비교적 안정적이거나 급락 대응 부족
- Stacking / Voting: 가장 안정적 추종

## 2024


- 패턴 안정 → 전체 모델 성능 향상
- 모든 모델이 유사한 흐름 예측
- 앙상블 모델이 여전히 가장 정확

## 2025


- 중간 급락 구간 발생 → 모델 공통 실패
- 이후 회복 구간은 비교적 잘 반영
- 앙상블 모델이 변동 완화 역할

# 시즌별 잠실(두산) 관중 수 예측 그래프


▶ 두산 | 2023년 시즌 후반 예측 추적



▶ 두산 | 2024년 시즌 후반 예측 추적



▶ 두산 | 2025년 시즌 후반 예측 추적



## 2023

- 급등·급락 반복 → 모델 오차 큼
- XGB / LGBM: 변동성 과소 반영
- 앙상블 모델: 상대적으로 안정적

## 2024

- 전 구간에서 지속적 하락 예측 (과소추정)
- 고점 유지 구간에서도 실제보다 낮게 예측
- XGB: 가장 큰 과소추정 (지속 하락)
- LGBM / CatBoost: 완만하지만 동일한 하락 패턴
- 앙상블: 일부 개선 있으나 여전히 낮음
- 전체 레벨을 못 맞춘 구조적 실패

## 2025


- 극단적 급락 후 급등 패턴
- 모든 모델이 급변 구간 대응 실패
- 모델 간 성능 차이보다 "공통 한계" 뚜렷

# 시즌별 고척(키움) 관중 수 예측 그래프

▶ 키움 | 2023년 시즌 후반 예측 추적



▶ 키움 | 2024년 시즌 후반 예측 추적



▶ 키움 | 2025년 시즌 후반 예측 추적



## 2023

- 비교적 단순한 패턴
- 대부분 모델이 추세 잘 반영
- 일부 구간에서만 소폭 오차

## 2024

- 완만한 하락 후 상승 구조
- 모든 모델이 유사한 패턴 예측
- 안정적인 성능 유지

## 2025

- 점진적 상승 패턴
- XGB / LGBM: 일부 변동 존재
- Stacking / Voting: 가장 부드러운 추세 반영

# 기아 홈경기 분석





2024년이 관중수 피크



기아 광주 구장은 전체적인 추세와 달리 2025년보다 2024  
년이 관중수가 높은편 입니다.



[/var/folders/3w/7bj38gqs0t58jb31pzzbbybr0000gn/T/ipykernel\\_8690/812203997.py:42:](#)  
bp = ax.boxplot(data\_by\_year, labels=[f'{y}년' for y in years], patch\_artist=Tr



# 기아 홈경기 분석




높은 관중수의 비결은 높은순위




2023,2025년에 비해 2024년이 압도적으로 높은 순위를 유지하면서 많은 관중수를 유지하였습니다.  
반면, 성적이 안좋은 2025년의 경우 관중 수의 추세가 상대적으로 떨어지는 형상을 보여줍니다.


□ 연도별 KIA 타이거즈 홈경기 기준 일간순위 추세  
〔2023년〕 KIA 챔피언스필드 홈팀 순위 추세



〔2024년〕 KIA 챔피언스필드 홈팀 순위 추세



〔2025년〕 KIA 챔피언스필드 홈팀 순위 추세



# 롯데 홈경기 분석




## 눈에 띄는 2025년 매진 기록



전체적인 추세와 맞게 2023,2024,2025년 해가 지날수록 관중수가 늘어나고 있습니다.

특히 2025년 4월말~6월말 까지 연속 매진 기록이 눈에 띕니다.



# 롯데 홈경기 분석



전년도 순위에 비해 높은 순위 유지가 비결




2025년 4월말 부터 3위권의 순위를 유지하면서 높은 관중수를 유지하였습니다.


시즌 중반에는 비록 순위는 유지하고 있지만 계속된 패배로 매진행렬은 이어나가지 못한 것으로 보입니다.

□ 연도별 홈경기 기준 일간순위 추세


(2023년) 롯데 홈팀 순위 추세








(2024년) 롯데 홈팀 순위 추세



(2025년) 롯데 홈팀 순위 추세



# 시즌별 기아 관중수 예측 그래프







비교적 높고 낮은 수치를 모델이 잘 잡아내었습니다.

1위라는 변수가 너무 크게 작용해 다른 변수를 무시하는 결과가 발생하였습니다. 모델에 추가적인 가중치를 부여하였으나 결과를 좋게 바꾸기는 한계가 있습니다.

시즌 후반 기아의 순위가 떨어지면서 예측 값보다 실제값이 낮게 나왔습니다.

# 시즌별 롯데 관중수 예측 그래프



모델들 별로 비슷하게 예측하였으나 선형회귀 모델, LightGBM은 오차가 좀 있는 편입니다.

전반은 추세를 잘 잡지못하나 후반에는 조금 잘 나온 편입니다.

시즌 성적이 후반에 낮아진 것에 비해 꾸준히 높은 관중추세를 모델이 정확하게 잡아내지 못하였습니다.

# 03



## MLB 관중수 분석, 예측



Major League Baseball



<https://www.mlb.com/>



# MLB 데이터셋 VS KBO 데이터셋 비교



## MLB 데이터셋의 장점



- **공식 API의 존재 여부:** MLB는 메이저리그는 공식 API(MLB Stats API)를 열어두고 있다. 반면 KBO는 오픈 API가 없어서, 크롤링 방식을 써야 합니다.
- **오픈소스 생태계와 라이브러리:** pybaseball이나 MLB-StatsAPI 같은 전용 라이브러리를 만들어져 있습니다.
- **데이터의 표준화:** MLB는 선수, 팀, 구장에 대한 고유 ID가 수십 년 전부터 완벽하게 통일되어 있다. KBO는 사이트마다 선수 이름 표기나 식별 방식이 달라서 데이터를 병합할 때 오류가 자주 발생하기도 합니다.
- **고급 트래킹 데이터의 개방:** MLB는 타구 속도, 발사 각도, 회전수 같은 최첨단 데이터를 대중에게 100% 공개하지만, KBO의 트랙맨이나 PTS 데이터를 일반인이 구하기 힘들 수 있습니다.

RETROSHEET

홈

찾다

게임/사람들/공원 ↓

니그로 리그 ↓

데이터 다운로드 ↓

특징 ↓

레트로 데이터 사용 ↓

**레트로시트에 오신 것을 환영합니다!**

레트로시트는 1989년, 1984년 이전 메이저리그 경기의 실황 기록을 최대한 많이 전산화하기 위해 설립되었습니다. 레트로시트는 설립 당시의 목표를 유지하면서도 메이저리그 경기에 대한 정보를 제공하는 데 주력해 왔으며, 확장되었습니다. 저희 단체와 역사에 대한 자세한 내용은 [여기에서](#) 확인하실 수 있습니다.

레트로시트의 현재 목표는 메이저리그 역사상 모든 야구 경기에 대한 정보를 최대한 많이 제공하는 것입니다. 위의 메뉴를 통해 저희가 수집한 자료들을 살펴보실 수 있습니다. 현재 보유하고 있는 경기 데이터는 아래에 요약된 레트로시트 홈페이지(이 페이지)로 돌아가시려면 어느 페이지에서든 레트로시트 로고(방향이 모양)를 클릭하세요.

레트로시트는 전적으로 자원봉사자들의 노력으로 운영되는 단체입니다. 저희는 언제나 더 많은 자원봉사자를 환영합니다. 저희 활동에 참여하고 싶으신 분은 레트로시트 회장인 톰 트레스(Tom Thress, [tthress@retrosheet.org](mailto:tthress@retrosheet.org))에게 연락주세요. 저희는 전액 기부금으로 운영됩니다. [기부](#)를 원하시는 경우, 기부 방법은 [여기에서](#) 자세히 확인하실 수 있습니다.

### 뉴스

2025년 11월 27일: Retrosheet의 2025년 두 번째 반기별 업데이트가 발표되었습니다. 자세한 내용은 [여기](#)를 참조하세요.

2025년 8월: Retrosheet의 2025년 첫 번째 반기별 보고서가 발표됩니다. 자세한 내용은 [여기](#)를 참조하세요.

### 레트로시트의 게임 컬렉션

레트로시트 기준으로 Retrosheet는 다음과 같은 게임 데이터를 수집했습니다.

1900년부터 2025년까지의 모든 아메리칸 리그(AL)와 내셔널 리그(NL) 시즌, 그리고 1914년과 1915년 페더럴 리그(Federal League)의 경기 기록이 포함되어 있습니다. 일부 기록은 신문 기사와 경기 기록표를 바탕으로 수집되었습니다. 1910-1911, 1913-1959, 1962-1968 시즌의 일부 경기는 추론을 통해 확보되었습니다.

1871년, 1872년, 1874년 북미 리그 시즌, 1898년부터 2024년까지의 내셔널 리그 시즌, 그리고 아메리칸 리그(1901년~2024년)와 플로리다 리그(1914년~1915년)의 전체 역사에 대한 경기 기록 데이터가 수집되었습니다.

니그로 리그 데이터는 1935년부터 1949년까지의 시즌에 대해 수집되었습니다. 또한, 1937년 이전에 열린 수백 건의 주요 경기에 대한 니그로 리그 데이터도 수집되었습니다.

Retrosheet의 기존 데이터(이벤트 파일, 박스스코어 파일, 게임 로그 등) 전체를 [여기에서](#) 다운로드하세요. (326MB 압축 파일)

각 선수의 일일 기록 및 경기 진행 상황을 자세히 분석한 CSV 파일 세트를 [여기에서](#) 다운로드하세요 (710MB 압축 파일).

[사이트맵](#)

# MLB 데이터셋 VS KBO 데이터셋 비교



## MLB 투수 데이터 추가



- 선발 투수: home\_sp\_era(홈팀 선발 평균자책점),
- away\_sp\_era(원정팀 선발 평균자책점),
- sp\_era\_diff(선발 ERA 차이), home\_sp\_is\_ace(홈팀 에이스 등판 여부),
- away\_sp\_is\_ace(원정팀 에이스 등판 여부),
- any\_ace\_pitching(양팀 에이스 등판 여부)

### 1.3 선발투수 ERA + 경기 시간(Day/Night) 보충 수집

- statsapi.schedule() 에서 경기 시작 시간 수집 → Day/Night 판별
- statsapi.get('game') boxscore에서 선발투수 시즌 ERA/승수 수집
- 캐시 파일로 저장하여 재실행 시 API 호출 방지

```
# — 1-3b. 선발투수 ERA + Day/Night 보충 수집 —————
PITCHER_CACHE = DATA_DIR / 'mlb_pitcher_time_cache.csv'

if PITCHER_CACHE.exists():
    df_pitcher = pd.read_csv(PITCHER_CACHE)
    print(f'✅ 선발투수/시간 캐시 로드: {len(df_pitcher):,}건')
else:
    print(f'🕒 선발투수 + 경기시간 수집 시작...')
    pitcher_records = []

    for season in sorted(df_all['season'].unique()):
        season = int(season)
        print(f'\n 📅 {season}시즌 스케줄 조회...')
        try:
            sched = statsapi.schedule(
```


# MLB 데이터셋 VS KBO 데이터셋 비교



## 최근100경기 관중수 추세 예측




1. 실제 관중 수와 여러 머신러닝 모델의 예측값을 비교한 것으로, 전체적인 흐름은 비교적 잘 맞추고 있습니다.
2. 특히 앙상블 모델과 LightGBM이 가장 높은 성능( $R^2$  약 0.63)을 보여 안정적인 예측을 보여줍니다.
3. 하지만 관중 수가 크게 늘거나 줄어드는 극단적인 경우는 잘 맞추지 못하는 한계가 있습니다.
4. 또한 예측값이 실제보다 덜 변동하여 전체적으로 평균에 가까운 값으로 치우치는 경향이 있습니다.



# MLB 시계열 모델



## 시계열 데이터 성능 비교분석



### 1. 전체 성능

- SARIMAX > Prophet >> Chronos
- SARIMAX ( $R^2 \approx 0.58$ ), Prophet ( $R^2 \approx 0.57$ ), Chronos ( $R^2 \approx 0.34$ )

### 2. 모델별 특징

- SARIMAX
  - 단기 변동 반영 가장 우수
  - 실제값 추종력 높음
- Prophet
  - 추세는 잘 포착
  - 변동성 과소/과대 추정 (신뢰구간 넓음)
- Chronos
  - 전반적으로 과소추정
  - 패턴 학습 부족

### 3. 공통 한계

- 급락/급등 구간에서 모든 모델 예측 실패
- 극단값(outlier) 대응 어려움


### 4. 인사이트

- 단순 시계열 모델만으로는 한계 존재
- → 외부 변수(팀 성적, 날씨, 이벤트 등) 필요

# MLB 시계열 모델



## GBM v4 기반 관중 예측 모델 성능 분석



### 1. 전체 모델 비교: GBM의 압도적 추종력

- 현황: 실제 관중 수의 큰 편차(1만~4.5만) 및 G7 구간 급락 발생
- 결과: GBM 기반 모델(v2~v4)이 시계열 모델 대비 급격한 변동 패턴을 가장 민감하고 정확하게 추종함

### 2. 예측 정확도 지표: v4 모델의 정밀도 확보

- 결정계수 ( $R^2$ ): GBM v2~v4 (0.9 내외) > 시계열 모델 (최대 0.57)
- 오차율 (MAPE): GBM v4-Ens (6.6%) 기록
  - 초기 모델(v1, 23.4%) 대비 약 3.5배 정확도 향상
  - 전통적 시계열 모델 대비 2~3배 우수한 정밀도 달성

### 3. 경기별 안정성: 외생 변수 대응력 입증

- 오차 관리: 시계열 모델이 특정 경기에서 최대 50% 오차를 보일 때, v4는 전 경기 고르게 낮은 오차율 유지
- 강건성: 변동성이 극심했던 G7 경기 등에서도 안정적 예측 수행으로 외부 변수 반영 성능 입증

# 04




## 시계열 모델의 적합성 분석



History, Rules, and the Spirit of America's Favorite Game



[www.reallygreatsite.com](http://www.reallygreatsite.com)



# 시계열 모델 적합성



야구데이터는 시계열 모델이 적합할까?



## 시계열 모델 적합성 분석

관중수 데이터는 시간의 흐름에 따라 변화한다는 점에서 일정 부분 시계열적 특성을 가지지만, 전형적인 시계열 데이터처럼 뚜렷한 추세나 계절성이 강하게 나타나지는 않습니다. 일부 구간에서는 시즌 진행에 따른 증가 경향이 관찰되지만, 전체적으로는 경기별 변동성이 크고 팀 인기, 구장, 일정과 같은 외부 요인의 영향이 더 크게 작용하는걸로 볼 수 있습니다.

이에 따라 시계열 모델과 일반 머신러닝 모델을 비교한 결과, 전반적으로는 트리 기반의 정형 데이터 모델이 더 높은 예측 성능을 보입니다. 그러나 데이터를 시간 순서대로 분리한 경우에는 이러한 모델들도 성능이 크게 저하되었으며, 반대로 랜덤하게 데이터를 분리했을 때는 예측 성능이 상승하는 경향이 나타났습니다.

이는 관중수 데이터가 시간에 따라 구조가 변화하는 특성을 일부 가지면서도, 동시에 정적인 패턴에 의존하는 혼합적 성격을 가지고 있음을 의미합니다. 즉, 시간 정보를 완전히 반영할 경우 예측이 어려워지고, 랜덤 분할에서는 유사한 패턴이 학습 데이터에 포함되면서 성능이 과대평가될 가능성이 있다.


# 시계열 모델 적합성 결론

## 핵심 정리

- 관중수 데이터는 시계열 + 정형 특성이 결합된 혼합형 데이터
- 시간 흐름보다 팀 인기, 구장, 일정 등 외부 요인의 영향이 더 큼
- 시계열 모델과 정형 모델 모두 완벽히 적합하지는 않음
- 따라서 단순 예측보다 관중에 영향을 주는 요인 분석이 더 중요

## 한 줄 결론

관중수 데이터의 가치는 예측이 아니라, 관중을 결정하는 요인을 밝히는 데 있습니다.



# 05



sabermetrics로의 확장




History, Rules, and the Spirit of America's Favorite Game



[www.reallygreatsite.com](http://www.reallygreatsite.com)




# sabermetrics EDA




**wRC+ (Weighted Runs Created Plus, 조정 득점 창출력)**를 부르는 약칭으로, 타자가 얼마나 득점에 기여했는지를 나타내는 가장 정확한 타격 지표 중 하나입니다. 리그 평균을 100으로 설정하여, 100보다 높으면 평균 이상, 낮으면 평균 이하의 타자임을 직관적으로 보여줍니다.

**WAR(Wins Above Replacement, 대체 선수 대비 승리 기여도)**은 특정 선수가 2군 선수나 최저 연봉 수준의 '대체 선수'에 비해 팀에 몇 승을 더 가져다주었는지를 나타내는 종합 능력 지표입니다. 타격, 주루, 수비(투수는 투구)를 모두 포함하여 한 숫자로 환산한 세이버메트릭스 수치입니다.


# sabermetrics EDA




시즌별 BABIP(운) 변화




볼넷 비율 VS 삼진 비율




실제 승률 VS 피타고리안 승률



홈런,볼넷, 삼진 비율이 전체타석에서 차지하는 비율



팀 OPS(장타율) VS 총 득점



시즌별 경기당 평균 도루 횟수



# [최종 정리: 데이터 분석을 통해 얻은 인사이트]





## 1. 데이터 접근성 및 확장성

지속 가능한 데이터: 수집 효율을 위해 정형화된 API 기반 데이터셋 우선 고려  
글로벌 호환성: KBO 모델의 MLB 확장 가능성 및 글로벌 분석 표준 확인

## 2. 야구 데이터의 본질: 시계열 vs 이벤트

시계열의 한계: 단순 추세보다는 날씨·요일·선발 등 외부 이벤트에 민감  
예측 너머의 분석: 단순 수치 예측보다 변동성을 유발하는 핵심 요인 분석이 중요



## 3. 최적의 모델링 전략

모델 다각화: 시계열(ARIMA 등)과 머신러닝(XGBoost 등)의 병행 분석  
Best-Fit 선별: 객관적 성능 비교를 통한 데이터 맞춤형 최적 모델 선정



## [최종 정리: 데이터 분석을 통해 얻은 인사이트]



### 4. 하이브리드 분석 체계

패턴과 변동성의 조화: 반복 패턴은 시계열로, 급격한 변동은 머신러닝으로 보완하는 하이브리드 모델 지향

<https://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE1156299>

### 5. 세이버메트릭스로의 확장

Performance x Marketing: 선수 성적이 실제 관중 동원에 미치는 영향력을 수치화  
트래킹 데이터 활용: 타구 속도, 회전수 등 정밀 데이터를 결합한 차세대 가치 평가 모델 구축





## 참고문헌



### 1. 머신러닝과 회귀분석을 활용한 관중수 예측방안 비교연구

- 저자: 이승용 (남서울대학교)
- 출처: 산업과 과학(Advanced Industrial Science), 제4권 제4호, pp. 36-48 (2025)
- 링크: <https://doi.org/10.23153/AI-Science.2025.4.4.036>

### 2. 머신러닝을 이용한 한국프로야구 관중 수 예측모델

- 저자: 서원빈, 길이만 (성균관대학교)
- 출처: 한국콘텐츠학회 종합학술대회 논문집, pp. 357-358 (2018)
- 링크: <https://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07455828> (학술대회 논문집 페이지)

<https://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE11562509>

### 3. DTW 및 시계열 군집분석을 활용한 프로야구 구단별 관중 규모 추이

- 저자: 김덕용, 장경호, 이현섭, 정연길, 강현민 (고려대학교)
- 출처: 지능정보연구(Journal of Intelligence and Information Systems), 제31권 제4호, pp. 217-234 (2025)
- 링크: <https://doi.org/10.13088/jiis.2025.31.4.217>

### 4. 기계학습을 이용한 한국 프로야구 관중 수 예측 모델 개발

- 저자: 조정환, 석부길 (한라대학교)
- 출처: 한국체육과학회지(The Korea Journal of Sports Science), 제32권 제5호, pp. 547-558 (2023)
- 링크: <https://doi.org/10.35159/kjss.2023.10.32.5.547>

# Thanks



저희 발표를 들어주셔서  
감사합니다.



팀: 올해는 우승



팀장: 최서연 팀원: 허수빈



롯데 우승하자

